

## План лекции

1. Задача нахождения оптимальных значений
2. Жадные алгоритмы. Задача об интервалах.
3. Применимость жадных алгоритмов.
4. Приближённое решение задачи о рюкзаке.
5. Алгоритм Хафмена.
6. Абстракция строка символов.
7. Динамические структуры данных.
8. Префиксное дерево.

# Задачи нахождения оптимальных значений

Задачи:

- ▶ Путешественник желает посетить несколько городов и потратить минимальную сумму денег.

# Задачи нахождения оптимальных значений

Задачи:

- ▶ Путешественник желает посетить несколько городов и потратить минимальную сумму денег.
- ▶ Управление дорожного движения хочет определить длительность фаз светофора, при котором будет обеспечен наибольший трафик.

# Задачи нахождения оптимальных значений

## Задачи:

- ▶ Путешественник желает посетить несколько городов и потратить минимальную сумму денег.
- ▶ Управление дорожного движения хочет определить длительность фаз светофора, при котором будет обеспечен наибольший трафик.
- ▶ Задача о рюкзаке.

# Экстремальные задачи

Экстремальные задачи — задачи на нахождение оптимальных (максимальных или минимальных) значений.

Решение таких задач — *оптимизация*.

*Некоторые* экстремальные задачи мы можем решить точно, некоторые — приближённо.

# Жадные алгоритмы

## Жадные алгоритмы

- ▶ состоят из итераций
- ▶ принимают решение на каждом шаге, стараясь найти *локально* оптимальное решение.

# Градиентный спуск

Пример типичного жадного алгоритма.

Имеется непрерывная функция  $n$  переменных  $f(x_1, x_2, \dots, x_n)$ , принимающая действительные значения на области определения.

Она определяет поверхность в  $n$ —мерном пространстве.

Один из алгоритм минимизации:

1. выбираем начальную точку  $(x_1, x_2, \dots, x_n)$ , она становится текущей точкой алгоритма.
2. обследуя точки вокруг текущей находим такую, в которой  $f(x'_1, x'_2, \dots, x'_n)$  имеет минимальное значение.
3. если найденная точка отлична от текущей, то делаем его текущей и переходим к второму шагу алгоритма.
4. конец.

## Пример градиентного спуска

$$f(x, y) = (x - 3)^2 + (y + 2)^2$$

Начальная точка ( $x_0 = 0, y_0 = 0$ ). Шаг поиска 0.1.

Осматриваем окрестности начальной точки.

$$f(0, 0) = 3^2 + 2^2 = 13$$

$$f(0 + 0.1, 0) = 2.9^2 + 2^2 = 8.41 + 4 = 12.41$$

$$f(0 - 0.1, 0) = 3.1^2 + 2^2 = 9.61 + 4 = 13.61$$

$$f(0, 0 + 0.1) = 9 + 4.41 = 13.41$$

$$f(0, 0 - 0.1) = 9 + 3.61 = 12.61$$

Победила точка (0.1, 0), она становится текущей точкой.



# Программа для решения задачи

```
#include <stdio.h>
double f(double x, double y) {
    return (x-3)*(x-3) + (y+2)*(y+2);
}
int main() {
    double x0 = 0., y0 = 0., d = 0.1;
    double dx[] = {d, -d, 0, 0}, dy[] = {0, 0, d, -d};
    double newx, newy;    bool bestfound = false;
    double maxf = f(x0, y0);
    while (!bestfound) {
        bestfound = true;
        for (int i = 0; i < 4; i++) {
            double newf = f(x0+dx[i], y0+dy[i]);
            if (newf < maxf) {
                maxf = newf;    bestfound = false;
                newx = x0+dx[i];    newy = y0+dy[i];
            }
        }
        if (!bestfound) {
            x0 = newx;    y0 = newy;
        }
    }
    printf("Best f(%.1f,%.1f)=%.2f\n", x0, y0, maxf);
}
```

## Пример градиентного спуска

Следующий шаг. Текущая точка  $(0.1, 0)$ .

Мы выбираем из точек  $(0.2, 0)$ ,  $(0, 0)$ ,  $(0.1, 0.1)$ ,  $(0.1, -0.1)$ , что приводит нас к следующей точке  $(0.2, 0)$

Далее маршрут проходит через точки от  $(0.3, 0)$  до  $(1, 0)$ , затем попеременно до  $(3, 2)$ .

Решение правильное.

# Градиентный спуск


А что произойдёт с решением задачи для функции  $(x - 3)^2 + 10 \sin x + (y + 2)^2$ ?

Наш алгоритм выдаст, что лучшим решением будет точка  $(-0.7, 2)$  с значением  $\approx 7.24$ , хотя минимум этой функции достигается в точке  $(\approx 4.4, -2)$  с значением  $\approx -7.6$ .

## Градиентный спуск

Функция  $(x - 3)^2 + 10 \sin x + (y + 2)^2$  имеет несколько локальных минимумов.

Её линии уровня:




# Градиентный спуск

Этот алгоритм, как и все жадные алгоритмы, склонен к нахождению локальных экстремумов.

# Задача об интервалах

# Задача об интервалах

**Задача 1.** На прямой дано множество отрезков. Необходимо найти максимальный размер множества непересекающихся отрезков.



# Задача об интервалах

Предлагается рассмотреть следующий вариант жадной стратегии:

- ▶ упорядочить отрезки по какому-либо признаку.
- ▶ рассматриваем отрезки по-одному. Если он не перекрывается с каким-либо из уже внесённым в выходное множество, то добавляем её в это множество.


Жадность алгоритма здесь заключается в том, что каждый раз, когда мы видим подходящий вариант (рассматривая очередной отрезок), то сразу его хватаем.

Принципов упорядочивания можно выбрать несколько, но, как оказывается, не все из них одинаково полезны.




## Задача об интервалах

По длительности. Сначала выберем самые короткие отрезки.




## Задача об интервалах

По длительности: итоговая расстановка:




## Задача об интервалах

По левой границе.




## Задача об интервалах

Итоговая расстановка:




## Задача об интервалах

По правой границе.



## Задача об интервалах


Итоговая расстановка



# Задача об интервалах

Как будто, все способы упорядочивания годятся?

А что насчёт такой расстановки?




# Задача об интервалах

Сначала самые короткие:



По левой границе и по правой границе:






Первый вариант не всегда даёт точное решение.


Поиск контрпримера: мы хотим найти опровергающий какую-либо гипотезу вариант (*зелёную ворону*).

Рассмотрим следующее расположение отрезков:



# Задача об интервалах

Упорядочивание по началу отрезка даёт нам:




Решение:




## Задача об интервалах

Упорядочивание по концу отрезка даёт нам:



И это приводит к верному решению:



# Задача об интервалах

Как доказать, что данный алгоритм верно решает задачу?

1. Первый шаг — доказательство того, что существует оптимальное подмножество отрезков, которое содержит первый отрезок, получившийся при применении нашего алгоритма. Если в некотором оптимальном подмножестве мы поменяем отрезок с минимальным значением конца на первый, то количество отрезков в подмножестве не изменится и подмножество останется решением. Таким образом, существует оптимальное подмножество, содержащее первый отрезок.
2. Второй шаг — удаляем из множества отрезков все отрезки, пересекающиеся с первым.
3. Третий шаг — повторяем алгоритм для усечённого множества, в котором находит первый отрезок.

Применив метод математической индукции, мы показали, что предложенный жадный алгоритм приводит к одному из оптимальных решений задачи.

Жадные алгоритмы не заглядывают вперёд. Они повторяют локально оптимальные по какому-либо критерию шаги и надеются, что решение будет глобально оптимальным. Возможно, что найдётся такой локально оптимальный критерий и общее решение окажется верным. Это бывает отнюдь не всегда, но тщательный выбор критерия может найти приемлемое решение.

# Применимость жадных алгоритмов. Приближённое решение экстремальных задач

Опять задача о рюкзаке.

Одно из точных решений имеет сложность  $O(2^N)$ .

Как найти приближённое решение?

## Формализация условия задачи о рюкзаке

**Задача о рюкзаке.** Пусть имеется  $N$  предметов, стоимость  $i$ -го предмета  $v_i$ , а масса  $w_i$ . Найти набор предметов с наибольшей стоимостью и не превосходящей заданного  $W$  массой.

**Приближённое решение** Попробуем применить следующий локально оптимальный алгоритм:

1. Расположим предметы в порядке убывания отношения  $\frac{v_i}{w_i}$ .  
Пусть они образуют упорядоченное множество  $B$ .
2. Установим оставшийся вес  $L = W$
3. Установим множество  $S = \emptyset$ .
4. Выбираем первый предмет  $I$  из упорядоченного множества, вес  $w_I$  которого не превосходит  $L$ .
5. Если такого предмета нет, то алгоритм закончен.
6. Кладём предмет в рюкзак, удаляя его из  $B$ :  
 $B \leftarrow B - I : L \leftarrow L - w_I; S \leftarrow S \cup I$ . Переходим к 4-му шагу.



Данный алгоритм приведёт к какому-либо решению.

Рассмотрим пример:

$$N = 3$$

$$W = 40$$

$$w_1 = 10; v_1 = 60$$

$$w_2 = 20; v_2 = 100$$

$$w_3 = 20; v_3 = 100$$

Алгоритм выберет последовательно первый и второй предметы. Их суммарная стоимость окажется 160.

Верное решение - выбрать второй и третий предметы. Их суммарная стоимость будет 200.

# Задача о сумме подмножества

**Задача 3.** Дано множество натуральных чисел  $S = \{a_1, a_2, \dots, a_n\}$  и натуральное число  $L$ . Найти такое подмножество, сумма элементов  $Sum$  такова, что  $Sum - L \geq 0$  и  $Sum - L \rightarrow \min$ .

Жадный алгоритм: сведение к жадной задаче с рюкзаком при стоимости равной  $a_i$  и весу, равному 1.

## Quiz

<http://rbtsv.ru/quiz/index>

# Сжатие информации. Алгоритм Хаффмана.

# Сжатие информации: алгоритм Хаффмана

**Задача 4.** Имеется текст, состоящий из символов. Закодировать его таким образом, чтобы:

- ▶ каждый из встречающихся символов получил свой двоичный код
- ▶ множество кодов было префиксным
- ▶ суммарная длина всех кодов для всех символов была бы минимальной.

# Алгоритм Хаффмана

Пример: пусть имеется текст, состоящий из множества из четырёх символов:

*AAAABAABABABABCBCAAAD*

Его длина — 21 символ.

Можно закодировать его следующим образом:

- ▶  $A \rightarrow 00$
- ▶  $B \rightarrow 01$
- ▶  $C \rightarrow 10$
- ▶  $D \rightarrow 11$

На кодирование каждого символа понадобится ровно два бита и общая длина кода составит 42 бита.

# Префиксный код

Неформальное определение: код, в котором не имеется кодовых слов, начинающихся с других кодовых слов.

Формальное определение: если существует код со строкой  $a$ , то кодов с непустой строкой  $ab$  не существует.

Пример: код

- ▶  $A \rightarrow 00$
- ▶  $B \rightarrow 10$
- ▶  $C \rightarrow 01$
- ▶  $D \rightarrow 101$

префиксным не является, так как кодовое слово символа  $D$  начинается с кодового слова символа  $B$ .

Другое название: *безпрефиксный*.

Ещё одно название — код, удовлетворяющий условиям Фано.

Наша задача — найти *минимальный префиксный код* для множества.

# Кодирование с помощью дерева


Ещё раз рассмотрим равномерный код из четырёх символов

- ▶  $A \rightarrow 00$
- ▶  $B \rightarrow 01$
- ▶  $C \rightarrow 10$
- ▶  $D \rightarrow 11$

Попробуем представить его в виде двоичного дерева.



## Двоичные деревья



Левая ветка - 0, правая ветка - 1.

# Алгоритм Хаффмана

AAAABAABABABABCBCAAAD

Определим частоты символов:

- ▶  $F_A = 12$
- ▶  $F_B = 6$
- ▶  $F_C = 2$
- ▶  $F_D = 1$

Нужно построить дерево, вес которого минимален.

$$\sum_{i=1}^n F_i \cdot L_i,$$


где  $L_i$  - глубина  $i$ -го символа.

# Алгоритм Хаффмана

Свойства оптимального дерева:


- ▶ Из каждого узла должно исходить ровно два пути.
- ▶ Не должно быть пустых вершин.
- ▶ Самое длинное кодовое слово должно быть парным.

# Алгоритм Хаффмана




# Алгоритм Хаффмана

Находим два самых редких символа.




# Алгоритм Хаффмана

Два самых редких символа должны находиться на самой длинной ветке. Если нет, то можно их поменять местами с символами на самой длинной ветке.



# Алгоритм Хаффмана

Два самых редких символа должны находиться на самой длинной ветке. Если нет, то можно их поменять местами с символами на самой длинной ветке.




# Алгоритм Хаффмана

Жадный алгоритм:


1. Помещаем в каждый узел частоту символа
2. Располагаем узлы согласно убыванию частот.
3. Для двух узлов с наименьшей частотой добавляем узел, который их соединяет.
4. В узел помещаем сумму частот детей
5. Помечаем узлы или вершины, как уже обработанные (отправляем вниз)
6. Если необработанных не осталось, то конец алгоритма
7. Переходим к шагу 2.




После шага 1



Шаги 2,3,4




## War 5




# Алгоритм Хаффмана

Следующая итерация:



# Алгоритм Хаффмана

Заключительное состояние:



# Алгоритм Хаффмана

Получившиеся коды:

- ▶  $A \rightarrow 0$
- ▶  $B \rightarrow 10$
- ▶  $C \rightarrow 110$
- ▶  $D \rightarrow 111$

Общая длина всех кодовых слов

$$12 \cdot 1 + 6 \cdot 2 + 2 \cdot 3 + 1 \cdot 1 = 31 < 42$$

# Задача о покрытии строки

Рассмотрим следующую задачу:

Имеется набор строк  $s_i, i = 1 \dots N$  - «слова», каждое из которых не начинается с другого (префиксный код).

Имеется длинная строка  $p$ .

Требуется определить, можно ли составить слово  $p$  из слов  $s_i$ .

Например, если слова  $s_i = \{ab, ca, ra, dab\}$ , то строку *abracadabra* из них составить можно  $ab + ra + ca + dab + ra$ , а вот слова *barca*, *abracadabraa* — нет.

# Задача о покрытии строки

Цель задачи — не просто найти решение, а найти оптимальное решение.

Главные параметры алгоритма:

- ▶  $N$  — длина строки  $p$ .
- ▶  $M$  — сумма длин строк  $s_i$ .

Решается ли эта задача жадным алгоритмом?



# Задача о покрытии строки

Жадный алгоритм:

1. Устанавливаем указатель позиции на начало «длинной» строки
2. Выбираем слово, которое полностью совпадает с подстрокой, начинающейся с указателя
3. Если такого слова не найдено, выводим «нет», завершение алгоритма
4. Если такое слово есть, перемещаем указатель на длину слова.
5. Если слово закончилось, то выводим «да» и завершаем алгоритм
6. Возвращаемся к пункту 2

# Задача о покрытии строки

C	A	B	B	A	C	A	A	C	A	B	A	B	A	C	C	A	B
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

A	B	A	C
---	---	---	---


A	B	B	A
---	---	---	---

B	A	C	A
---	---	---	---

C	A	B
---	---	---







A	C	A	B
---	---	---	---

# Задача о покрытии строки









Этап 1. Нашли первое слово.

# Задача о покрытии строки





Этап 2. Переместили указатель и нашли второе слово.

## Задача о покрытии строки



Этап 3. Переместили указатель и нашли третье слово.

## Оценка сложности алгоритма



# Оценка сложности алгоритма

- ▶ Определить, что слово подошло, мы можем только просмотрев всё слово.
- ▶ Определить, что слово не подошло, можно даже с первого символа слова.
- ▶ Грубо оценим количество попыток на слово длины  $L$  как  $\frac{L}{2}$
- ▶ Средняя длина слова есть  $L = \frac{M}{K}$
- ▶ При одном этапе поиска мы в среднем перебираем  $\frac{K}{2}$  слов, каждое средней длиной  $L$ .
- ▶ Каждый этап продвигает нас в среднем на  $L$  позиций в «длинной» строке, итого количество этапов  $T = \frac{N}{L}$
- ▶ Итого  $F = \frac{N}{L} \times \frac{K}{2} \times \frac{L}{2} = \frac{NK}{4} = O(NK)$

# Оценка сложности алгоритма

- ▶ Парадоксально, но сложность алгоритма не зависит от общей длины всех слов!
- ▶ Представим, что  $K = 1$ , то есть, ищется покрытие ровно одним словом длины  $M$  (пусть  $N \vdots M$ ).
- ▶ Тогда каждый успешный поиск продвигает нас по «длинной» строке на  $M$  позиций. Всего наибольшее количество поисков  $\frac{N}{M}$ , в каждом из которых сравнивается  $M$  символов.
- ▶ Итого  $F = O(N)$



# Исследование задачи для поиска другого алгоритма


- ▶ Для большого  $K$  алгоритм становится неэффективен.
- ▶ Имеется ли более короткое решение?

# Исследование задачи для поиска другого алгоритма

- ▶ Для большого  $K$  алгоритм становится неэффективен.
- ▶ Имеется ли более короткое решение?
- ▶ Да, если мы изменим структуру данных.
- ▶ Проблема в том, что мы, обнаружив несовпадение с одной подстрокой, ничего не получаем для следующих.
- ▶ Усложним представление тех строк, которые мы ищем.
- ▶ Попробуем производить поиск параллельно по всем подстрокам.
- ▶ Построим *префиксное дерево*


# Префиксное дерево

- ▶ Из каждого узла всегда выходит ровно три ветви,  $A$ ,  $B$  и  $C$ .
- ▶ Каждая из веток приходит или в узел, либо в вершину, либо в никуда.



# Префиксное дерево


- Для простоты не будем рисовать ветви, уходящие в никуда.



# Построение префиксного дерева


Слова: АВАС, АВВА, ВАСА, САВ, АСАВ

- ▶ Строим дерево для каждого слова посимвольно.
- ▶ Для первого слова, АВАС дерево будет таким:




## Построение префиксного дерева

- Додавим слова АВВА и ВАСА:



## Построение префиксного дерева

- Теперь слова САВ и АСАВ:



# Алгоритм построения префиксного дерева

1. Создаём вершину дерева — узел с пустыми ветвями.
2. Для каждого слова выполняем:
  - 2.1 Устанавливаем указатель в вершину дерева.
  - 2.2 Считываем очередную букву.
  - 2.3 Если текущий узел не содержит нужной ветви, создаём эту ветвь и пустой узел на ней.
  - 2.4 Переходим в нужную ветвь.
  - 2.5 Если узел уже серый или не пустой, завершаем алгоритм с неудачей.
  - 2.6 Если слово закончилось, то помечаем узел серым цветом.
  - 2.7 Переходим к 2.2
3. Завершаем алгоритм с успехом.



# Оценка сложности алгоритма

- ▶ Один шаг алгоритма продвигает нас на ровно один символ в образце.
- ▶ Повторно образцы не обрабатываются.
- ▶ Количество операций есть  $O(M)$ , где  $M$  — сумма длин образцов.

## Поиск с помощью префиксного дерева

- Поиск по получившемуся дереву стал совсем простым:

C	A	B	B	A	C	A	A	C	A	B	A	B	A	C	C	A	B
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---

